

Preprocessing Walkthrough — CLN_SG_V2

Bài toán: Dự báo liệu PAC tối ưu hàng ngày (Nongdo_Jartest_PAC)

1 Kết quả tổng quan

	Trước	Sau
Số dòng	2,191	2,036
Số cột	50	59 (gồm target)
Missing values	Có	0
Outliers	Có	Clipped
Features	11 raw	58 engineered
Scaling	—	Min-Max [8]

2 Biểu đồ xác minh

3 Pipeline 8 bước

3.1 Bước 1 — Load & Chuẩn hóa tên cột

NOTE

Một số cột có tên bị dư dấu cách (trailing whitespace) trong file Excel gốc — bước `.str.strip()` là bắt buộc.

3.2 Bước 2 — Loại bỏ cột quá nhiều Missing (> 50%)

Cột bị loại	Missing
Al_vao_nha_may	84.1%
Al_sau_loc	97.3%
Al_ra_nha_may	84.1%
Nongdo_Jartest_Phen	93.2%



Hình 1: Preprocessing Verification — phân phối target, train/val/test split, tương quan features

3.3 Bước 3 — Chọn Feature Set (11 chỉ tiêu đầu vào)

Chỉ dùng **chỉ tiêu tại đầu vào / nước thô** — tránh data leakage từ các bước xử lý sau:

Feature	Tên đầy đủ	Missing ban đầu
Doduc_vao_nha_may	Độ đục đầu vào (NTU)	0.2%
pH_Song_SG	pH sông Sài Gòn	3.1%
pH_vao_nha_may	pH tại đầu vào nhà máy	0.2%
Man_song_saigon	Độ mặn sông SG (mg/L)	2.3%
NH3_song_sai_gon	Amoniac nước thô (mg/L)	4.1%
Mn_vao_nha_may	Mangan đầu vào (mg/L)	0.2%
Fe_vao_nha_may	Sắt đầu vào (mg/L)	0.4%
DO_vao_nha_may	Oxy hòa tan đầu vào (mg/L)	2.0%
Mau_vao_nha_may_BK	Màu nước thô (Pt-Co)	0.3%
SS_vao_nha_may	Chất rắn lơ lửng đầu vào (mg/L)	7.4%
Thetich_Jartest_PAC	Thể tích PAC trong Jar test (mL)	5.3%

IMPORTANT

Không dùng Doduc_sau_lang, pH_ra_nha_may, hay các chỉ tiêu đầu ra khác làm feature — đây là kết quả của quá trình xử lý, không có trước thời điểm ra quyết định.

3.4 Bước 4 — Xử lý Missing Values

Lý do dùng linear interpolation thay vì mean/median fill:

- Dữ liệu thời gian liên tục — giá trị giữa 2 ngày đo là xấp xỉ tuyến tính hợp lý
- Mean fill sẽ xóa đi tính mùa vụ cục bộ

3.5 Bước 5 — Xử lý Outliers ($IQR \times 3$ Clipping)

NOTE

Dùng $IQR \times 3$ (thay vì $\times 1.5$ thông thường) để giữ lại các sự kiện đặc biệt (lũ, triều cường) mà vẫn loại bỏ lỗi đo lường.

Cột	Outliers bị clip	Khoảng sau clip
Doduc_vao_nha_may	21	[-32.2, 105.8] NTU
Man_song_saigon	14	[-44.6, 133.6] mg/L
Mau_vao_nha_may_BK	33	[-205.2, 724.5] Pt-Co
Thetich_Jartest_PAC	30	[3.8, 41.6] mL
pH_Song_SG	3	[4.66, 7.79]
NH3_song_sai_gon	6	[-0.92, 2.36] mg/L
Mn_vao_nha_may	6	[-20.3, 294.7] mg/L
SS_vao_nha_may	18	[-24.8, 89.0] mg/L

3.6 Bước 6 — Feature Engineering (58 features)

3.7 Bước 7 — Train / Val / Test Split (Time-Based)

IMPORTANT

Không dùng random split cho time-series! Random split gây **data leakage** vì model sẽ thấy dữ liệu tương lai trong lúc train. Luôn split theo thứ tự thời gian.

3.8 Bước 8 — Min-Max Normalization

Inverse transform khi đánh giá model:

4 Output Files

File	Kích thước	Mô tả
dataset/train.csv	1359×59	Dữ liệu train (scaled)
dataset/val.csv	358×59	Dữ liệu validation (scaled)
dataset/test.csv	319×59	Dữ liệu test (scaled)
dataset/processed_full.csv	2036×59	Full data chưa scale
dataset/scaler_params.json	59 entries	Min/max để inverse transform
dataset/metadata.json	—	Cấu hình đầy đủ pipeline

5 Cách dùng trong Model Training

TIP

Với **Liquid Neural Network (LTC)**, input shape là (batch, timesteps, features). Nên thử timesteps = 7 (1 tuần) hoặc timesteps = 14 (2 tuần) — phù hợp với lag features đã tạo.